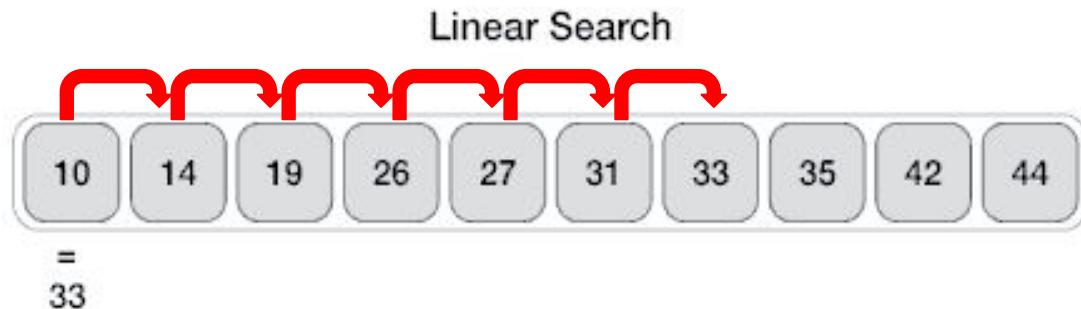


Tabelas *Hash*

Helena Graziottin Ribeiro
hgrib@ucs.br

Métodos de pesquisa ou busca

- Os métodos de **pesquisa** vistos até agora (sequencial, binária, por dicionários) buscam informações armazenadas com base na comparação de suas **chaves** (chave pode ser o próprio elemento procurado):



Métodos de pesquisa ou busca

- Chave de um registro (a chave pode ser numérica ou não):


Key	Value
K1	AAA,BBB,CCC
K2	AAA,BBB
K3	AAA,DDD
K4	AAA,2,01/01/2015
K5	3,ZZZ,5623

Métodos de pesquisa ou busca

- **Chaves** podem ser **nomes** de pessoas, por exemplo
- Solução: todo dado não numérico corresponde uma representação numérica no computador;
 - uma **função** pode converter o dado não numérico em numérico
- Assim, **todas as chaves são consideradas numéricas**

Métodos de pesquisa ou busca

- Para obtermos algoritmos eficientes, armazenamos os elementos ordenados e tiramos proveito dessa ordenação



O que é?

- Uma **tabela Hash**, também conhecida como **tabela de dispersão** ou **tabela de espalhamento**, é uma estrutura de dados especial, que associa **chaves** e valores, através de uma **função hash** (ou função de dispersão):
 - a partir de uma **chave simples**, essa função permite fazer uma busca rápida e obter o valor desejado
 - **forneço a chave**, e a **função hash** retorna a **posição** (ou endereço) da localização do valor


O que é?

- A **tabela *Hash*** é um conjunto de elementos, como um vetor:

0	
1	
2	
3	
4	

O que é?

- forneço a chave, e a **função hash** calcula e retorna a **posição** (ou endereço) da localização do valor




O que é? Exemplo



O que é?

- forneço a chave, e a **função hash** calcula e retorna a **posição** (ou endereço, ou índice) da localização do valor



situação ideal:
complexidade **$O(1)$**

Problema: definir uma boa função de *hash*

- a função *hash* faz um cálculo para definir uma posição possível na tabela *hash*:
 - exemplo de função *hash* “clássica” para um vetor:

chave % tamanho

resto da divisão inteira da **chave** pelo **tamanho do vetor**

Problema: definir uma boa função de *hash*

- a função *hash* pode ser qualquer cálculo:
 - o ideal é que a função forneça índices únicos para o conjunto das chaves de entrada possíveis:
 - sem repetir valor gerado
 - fácil de computar
 - uniforme (todos os locais da tabela sejam igualmente utilizados)

Problema: definir uma boa função de *hash*

- a função *hash* pode ser qualquer cálculo:
 - o que se quer é que ela distribua o melhor possível os valores dentro da tabela

espalhar bem
os valores

Problema: definir uma boa função de *hash*

- a função *hash* pode ser qualquer cálculo:
 - o que se quer é que ela distribua o melhor possível os valores dentro da tabela

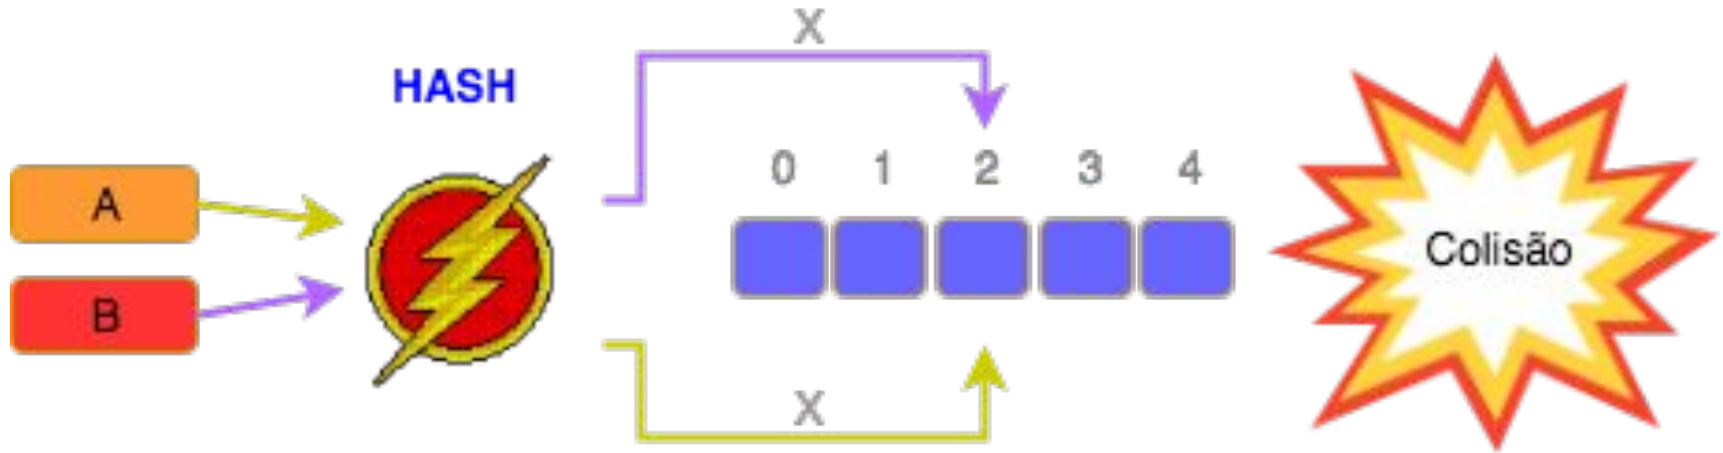
se todos os valores
forem conhecidos
antes da inserção,
ok!



espalhar bem
os valores


Problema: colisões

- Porém, se não forem, pode haver geração de **duas posições iguais** para **duas chaves diferentes**:



Problema: colisões


- pode haver geração de duas (ou mais) posições iguais para duas (ou mais) chaves diferentes:



Hashing: the crux of the problem

Problema: tamanho da tabela?

- é preciso saber o tamanho máximo da tabela: **M**
- ou “estimar” o tamanho máximo da tabela



Hashing: the crux of the problem

Implementações de tabelas hash

- As diferentes implementações de tabelas *hash* são diferentes formas de resolver colisões:
 - tabelas hash fechadas:
 - **linear** (*hashing* para busca linear)
 - **por buckets** (“depósitos”)
 - tabelas hash abertas:
 - **hashing aberto** (ou por encadeamento separado)

Implementações de tabelas hash: linear

- função **hash**: calcula a posição
- se der colisão, usa função de **rehash** (ou reespalhamento):
 - procura próxima posição livre

Exemplo:

$\text{hash} = \text{chave} \% \text{tamanho}$

$\text{rehash} = (\text{hash} + 1) \% \text{tamanho}$

Implementações de tabelas hash: linear

Exemplo: tabela *hash* com 11 posições

0	1001
1	1717
2	1003
3	3113
4	6977
5	
6	
7	
8	
9	
10	

1001: H=0

1003: H=2

1717: H=1

3113: H=0 (colisão); RH=1 (colisão); RH=2 (colisão); RH=3

6977: H=3; RH=4

$$1001 \% 11 = 0$$

$$(1001 / 11 = 91)$$

Implementações de tabelas hash: linear

O que seria um bom tamanho de tabela (**tam**)?

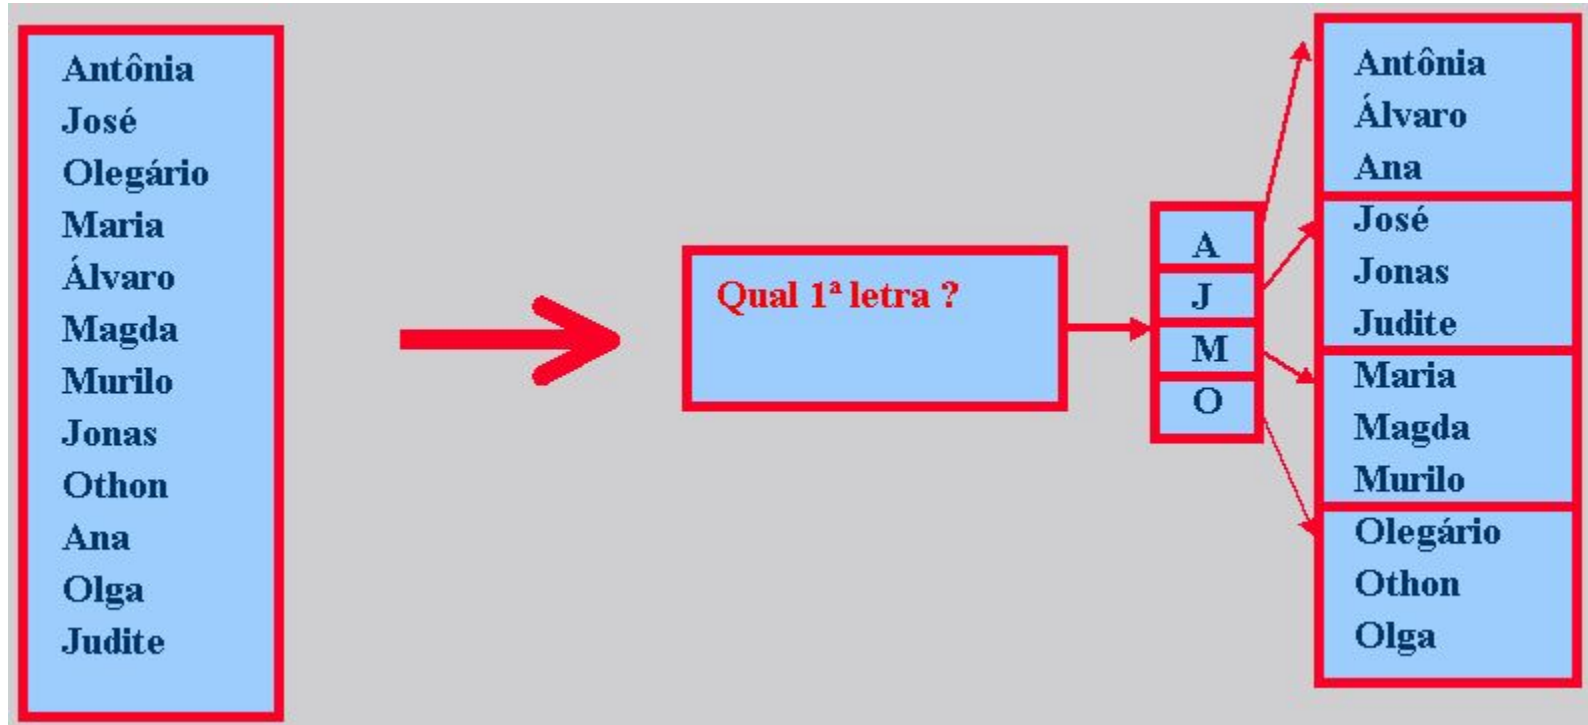
- Alguns valores de **tam** são melhores que outros
- Se **tam** é um número par, $hash(x)$ será par quando x for par e ímpar quando x for ímpar
 - Não é uma boa solução
- Se **tam** for uma potência de 2, $hash(x)$ dependerá apenas de alguns dígitos de x .
 - Não é uma boa solução

Implementações de tabelas hash: linear

O que seria um bom tamanho de tabela (**tam**)?

- Existem alguns critérios que têm sido aplicados com bons resultados práticos:
 - Escolher **tam** de modo que seja um número primo não próximo a uma potência de 2
 - Escolher **tam** tal que não possua divisores primos menores que 20
 - Exemplo: **tam = 23**

Implementações de tabelas hash: por *buckets*



Implementações de tabelas hash: *hashing aberto*


- Colisões: valores com mesmo *hash* ficam em lista encadeada associada à mesma posição

Implementações de tabelas hash: *hashing aberto*

0 (A)
1 (B)
2 (C)
3 (D)
4 (E)
5 (F)
⋮
⋮
⋮
⋮
⋮
⋮
24(Y)
25(Z)

insere "Ana"

Implementações de tabelas hash: *hashing aberto*

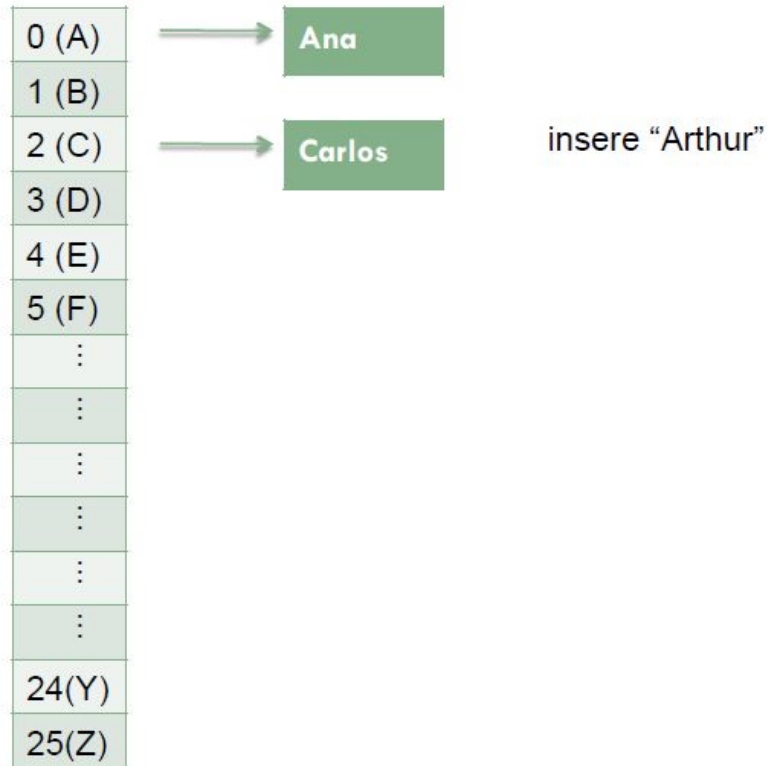


Implementações de tabelas hash: *hashing aberto*

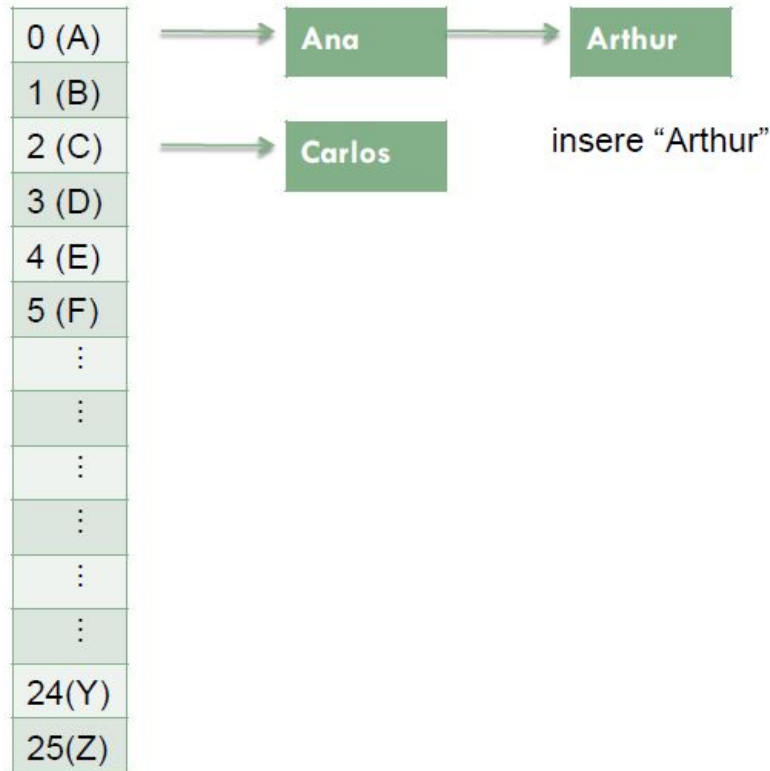
0 (A)	→ Ana
1 (B)	
2 (C)	
3 (D)	
4 (E)	
5 (F)	
⋮	
⋮	
⋮	
⋮	
⋮	
⋮	
24(Y)	
25(Z)	

insere "Carlos"

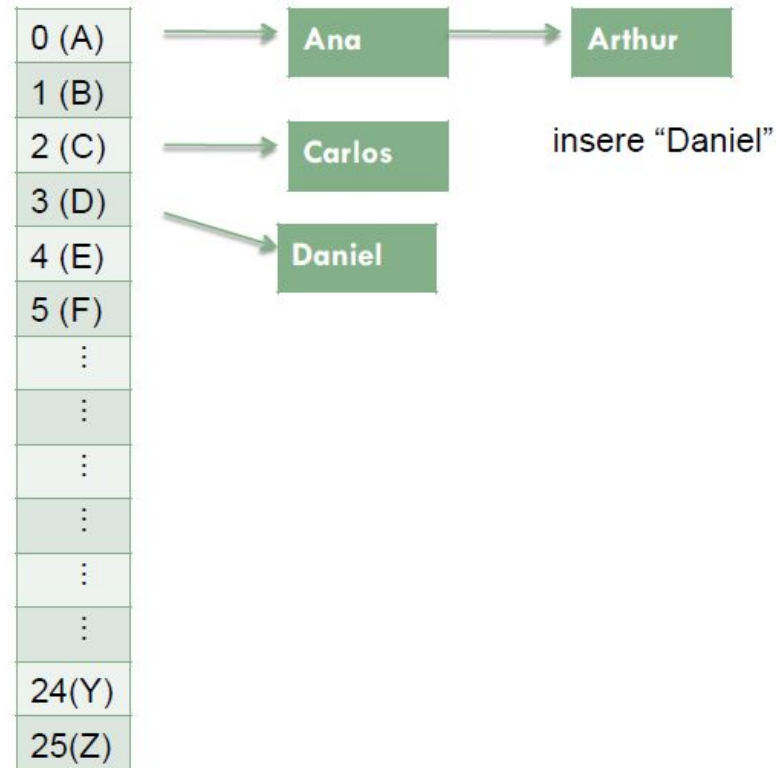
Implementações de tabelas hash: *hashing aberto*



Implementações de tabelas hash: *hashing aberto*



Implementações de tabelas hash: *hashing aberto*



Implementações de tabelas hash: *hashing aberto*

