





COMPUTAÇÃO PARALELA: UMA INTRODUÇÃO

Arquitetura de Computadores

COMO GANHAR DESEMPENHO EM PROGRAMAS?

- 3 opções



COMO GANHAR DESEMPENHO EM PROGRAMAS?

Melhorar o ambiente de execução

- Ex: Comprar um processador melhor


Melhorar o algoritmo

- Ex: substituir um algoritmo de ordenação Bubble por Quicksort

Paralelização

- Não é a solução para todos os problemas do mundo
- Alguns problemas não são paralelizáveis (ou muito difíceis de se ganhar desempenho)

Figure 9. How much time do you spend in a month to performance tune your application?




Data: UBM TechWeb Survey of 275 software engineers or managers of development teams, October 2011

COMPUTAÇÃO SEQUENCIAL

Programa executa em uma única CPU


- Dividido em uma série de instruções
- Executadas uma após a outra*
- Apenas uma instrução é executada por vez*



COMPUTAÇÃO PARALELA

Utilização de múltiplos recursos computacionais para resolver um determinado problema

- Múltiplas CPUs
- Problemas são divididos para serem executados simultaneamente



COMPUTAÇÃO PARALELA

“A parallel computer is a collection of processing elements that cooperate and communicate to solve large problems fast.”

Almasi and Gottlieb, Highly Parallel Computing, 1989

POR QUE USAR PARALELISMO?

Economizar Tempo/Dinheiro

Solução de grandes problemas (Internet das Coisas, Big Data, Simulação computacional)

- O mundo real é massivamente paralelo


Aumento de desempenho de um único processador

- aumento do tamanho da palavra, da precisão e da capacidade de memória
- tecnologia de substratos mais finos, mais transistores em menor espaço, maiores e mais rápidas vias de comunicação

Fazer melhor uso dos recursos

- Cluster
- Grids

Figure 3. What was the primary reason for conversion?



Base: 59 directors or managers of development teams who are converting serial applications to parallel code
Data: UBM TechWeb Survey of 275 software engineers or managers of development teams, October 2011

POR QUE USAR PARALELISMO?

Limite da computação sequencial

Limites da transmissão de sinais elétricos

- Velocidade de transmissão faz com que módulos tenham que ser colocados relativamente perto um dos outros para não perder sincronização

Limites na miniaturização dos componentes (Lei de Moore)

Limites econômicos

- aumento da velocidade dos processadores faz com que outros componentes tenham que ser modificados para trabalhar com maior velocidade → aumento de custo
- aumento da densidade de transistores
 - aumenta a complexidade do processo de preparação do substrato para a implementação da matriz de transistores e as ligações que os conectam e necessita-se desenvolver novos isoladores e dissipadores de calor

ONDE ESTÁ O PARALELISMO?

Paralelismo no nível de instruções

- Pipeline, superescalar, execução fora de ordem
- *Instruction level parallelism* (ILP): ~1985 até os dias atuais

Implicito para o programador

Várias linhas de execução: threads

- Suporte do sistema operacional




Vários núcleos

Vários processadores

Placas Gráficas (GPUs)

Programador é responsável pela exploração do paralelismo

ONDE ESTÁ O PARALELISMO?



ONDE ESTÁ O PARALELISMO?

IEEE Spectrum FOR THE TECHNOLOGY INSIDER

QUEST ARTICLE COMPUTING

Can Software Performance Engineering Save Us From the End of Moore's Law? > There's a lot of to gain from writing more efficient code

BY CHARLES E. LEISERSON TAO B. SCHARDL KEIL C. THOMPSON | 04 JUN 2020 | 3 MIN READ |



```
elif operation == "MIRROR_Y":
    mirror_mod.use_x = False
    mirror_mod.use_y = True
    mirror_mod.use_z = False
elif operation == "MIRROR_Z":
    mirror_mod.use_x = False
    mirror_mod.use_y = False
```

While software performance engineering may be the best path forward, it won't be an easy one. Updating existing programs to run more quickly is a huge undertaking, especially with a shortage of coders trained in parallel programming and other performance-engineering strategies. Moreover, leaders of forward-looking companies must fight against the institutional inertia of doing things how they've always been done.

June 16, 2014

Tiny Titan Preps Students for Multicore Era

Tiffany Trader





Supercomputing can be daunting to the uninitiated. A peek at the hardware, for example, with row after row of black boxes, reveals little of the exciting science that is being enabled by these ultra-fast computations. To help make the world of HPC a little less opaque, staff members at Oak Ridge National Labs (ORNL) created a scaled down version of the Titan supercomputer. The team developed a nine-core portable unit that communicates its core activity with lights.

PHYS.ORG

High-performance computing programming with ease

As high-performance computing (HPC) bends to the needs of "big data" applications, speed remains essential. But it's not only a question of how quickly one can compute problems, but how quickly one can program the complex applications that do so.

ÁREAS DE APLICAÇÃO




	Segments	Count	System Share (%)	Rmax (GFlops)	Rpeak (GFlops)	Cores
1	Industry	196	39.2	1,522,959,430	2,479,767,377	22,108,760
2	Research	141	28.2	5,119,807,438	7,694,949,554	72,921,380
3	Academic	103	20.6	888,825,778	1,311,734,384	11,578,332
4	Government	28	5.6	180,573,250	258,175,043	4,108,796
5	Vendor	21	4.2	390,054,960	569,911,203	3,169,632
6	Others	11	2.2	111,116,000	186,399,200	826,128

ARQUITETURAS PARALELAS

Na década de 1960, Michael J. Flynn propôs uma classificação de arquiteturas paralelas com base no fluxo de instruções e de dados (utilizada até hoje)


M. J. Flynn, "Some Computer Organizations and Their Effectiveness," in IEEE Transactions on Computers, vol. C-21, no. 9, pp. 948-960, Sept. 1972, doi: 10.1109/TC.1972.5009071.



CLASSIFICAÇÃO DE FLYNN: SISD

Single Instruction stream, Single Data stream


- Computadores com um único processador (modelo von Neumann), mas que ainda podem explorar o paralelismo em nível de instrução
 - Motorola 68000, Intel 80386, Intel Pentium
- Instruções executadas em sequência
- Pode-se saber o que está ocorrendo a cada instante de tempo e reproduzir tudo mais tarde (determinismo)



CLASSIFICAÇÃO DE FLYNN: SIMD

Single Instruction stream, Multiple Data stream


- Cada processador executa a mesma instrução em sincronia, mas em diferentes dados
- A extensão de conjunto de instruções *Streaming SIMD Extensions (SSE)* do x86 realiza a mesma instrução em diversos registradores simultaneamente
- As *Graphics Processing Unit (GPU)* são representantes desta classe
 - General Purpose Graphics Processing Unit (GPGPU)



CLASSIFICAÇÃO DE FLYNN: MISD

Multiple Instruction stream, Single Data stream


- Envolve múltiplos processadores executando diferentes instruções em um único conjunto de dados
- Não existem representantes desta categoria



CLASSIFICAÇÃO DE FLYNN: MIMD

Multiple Instructions, Multiple Data



- Relacionam arquiteturas compostas por vários processadores independentes, onde se executam diferentes fluxos de instruções em dados locais a esses processadores
 - Não determinismo: várias coisas ocorrendo ao mesmo tempo
- Classe dos computadores paralelos (processadores multicore também se enquadram)



CLASSIFICAÇÃO DE FLYNN: MIMD


Memória Compartilhada

- *Symmetric Multiprocessor (SMP), Multicore*




Memória Distribuída

- *Cluster, MPP (Massively Parallel Processing)*



Híbridas

- *Combinação de compartilhada e distribuída*



SUPERCOMPUTADOR #1 (JUNHO 2024)




LOCAL	SISTEMA	CORES	RMAX (TFLOP/S)	RPEAK(TFLOP/S)	POWER (KW)
DOE/SC/Oak Ridge National Laboratory United States	Frontier - HPE Cray EX235a, AMD Optimized 3rd Generation EPYC 64C 2GHz, AMD Instinct MI250X, Slingshot-11, HPE	8.699.904	1.206,00	1..714,81	22.786

SUPERCOMPUTADOR #2 (JUNHO 2024)




LOCAL	SISTEMA	CORES	RMAX (TFLOP/S)	RPEAK(TFLOP/S)	POWER (KW)
DOE/SC/Argonne National Laboratory United States	Aurora - HPE Cray EX - Intel Exascale Compute Blade, Xeon CPU Max 9470 52C 2.4GHz, Intel Data Center GPU Max, Slingshot-11, Intel	9.264.128	1.012,00	1.980,01	38.698

SUPERCOMPUTADORES – DESEMPENHO (JUNHO 2024)



- Xeon Gold 62xx (Cascade Lake)
- AMD Zen-3 (Milan)
- AMD Zen-2 (Rome)
- Xeon Gold (Skylake)
- Xeon Platinum 83xx (Ice Lake)
- Xeon Platinum 82xx (Cascade Lake)
- Xeon Platinum (Sapphire Rapids)
- Intel Xeon E5 (Broadwell)
- AMD Zen-4 (Genoa)
- Xeon Platinum (Skylake)
- Others



SUPERCOMPUTADORES – ARQUITETURA (JUNHO 2024)

